

Universidad del Valle de Guatemala

Data Science · Sección 10

Laboratorio 4

ML y GIS · Parte 2

Avance reproducible — 75%

Clasificación de concentraciones altas de cianobacterias
en los lagos de Atitlán y Amatitlán

Jorge Gabriel Palacios Sales	231385
Pablo Daniel Barillas Moreno	22193
Roberto Emiliano Otoniel	23968

20 de agosto de 2026

Abstract

Se construyó un conjunto de aprendizaje supervisado a nivel píxel–fecha con las 22 observaciones Sentinel-2 L2A de la Parte 1. Se descargaron diez bandas espectrales a 20 m, se aplicaron máscaras de calidad y agua, y se definió una respuesta binaria de concentración alta mediante un umbral de 100 000 células/mL. Para impedir fuga de información, se excluyeron CYA y todas las variables que participan directa o indirectamente en su ecuación. Se compararon regresión logística, Random Forest y Gradient Boosting bajo partición aleatoria 70/30, GroupKFold espacial, retención temporal y transferencia entre lagos. Gradient Boosting obtuvo ROC-AUC 0.999 y F1 0.957 en la prueba aleatoria, pero la retención temporal redujo su F1 a 0.665. Esta diferencia demuestra por qué la validación geográfica y temporal es necesaria.

1 Alcance de este corte

Este avance completa los ejercicios 1–7 y la importancia global del ejercicio 8. Se deja deliberadamente para la entrega final el análisis SHAP local y direccional, los mapas completos de probabilidad y errores, la comparación cartográfica exhaustiva con la Parte 1 y las conclusiones integradas. El código, las tablas y el notebook permiten regenerar todos los resultados presentados.

2 Preparación del dataset

2.1 Fuente, unidad de análisis y limpieza

La unidad de análisis es un píxel acuático válido de 20 m observado en una fecha y un lago. Cada fila contiene lago, fecha, coordenadas UTM 15N y WGS84, bandas espectrales, NDVI, NDWI, CYA, variables temporales, bloque espacial y respuesta binaria. Se usaron las once fechas oficiales por lago de la Parte 1.

La descarga openEO se recortó con los GeoJSON del curso y el contorno del espejo de agua. La capa SCL excluyó NoData, píxeles defectuosos, sombra de nube, nube media/alta, cirros y nieve; también se exigió reflectancia positiva y $\text{NDWI} \geq 0$. Los porcentajes de la Tabla 1 usan como denominador la envolvente rectangular del raster, por lo que miden conjuntamente recorte geométrico, agua y calidad; no equivalen a porcentaje de nubosidad.

Table 1: Inventario completo antes del muestreo de modelado.

Lago	Fechas	Píxeles raster	Válidos	Válidos (%)
Atitlán	11	7 725 564	3 041 752	39.37
Amatitlán	11	1 926 210	377 304	19.59
Total	22	9 651 774	3 419 056	35.42

Para mantener un costo computacional manejable se tomó una muestra aleatoria reproducible de 10 000 píxeles por lago–fecha, sin sobremuestrear ninguna clase: 220 000 filas y 27 columnas. No quedaron valores faltantes. Los conteos de limpieza y prevalencia se calcularon sobre los 3.42 millones de píxeles válidos completos, no sobre la muestra.




Figure 1: Exploración de CYA, NDVI y NDWI en la muestra reproducible.

3 Respuesta binaria y desbalance

Se definió $Y = 1$ (concentración alta) cuando $CYA (10^3 \text{ células/mL}) \geq 100$, equivalente a 100 000 células/mL. La referencia ambiental es el nivel histórico de alerta moderada de la OMS para agua recreativa. Se usa únicamente como umbral de cribado: Se2WaQ es una estimación óptica transferida y no una medición microscópica, taxonómica o toxicológica. Por tanto, una predicción alta debe motivar verificación in situ y no interpretarse como diagnóstico sanitario.

Table 2: Distribución completa de la respuesta.

Lago	Baja	Alta	Alta (%)
Atitlán	3 030 910	10 842	0.36
Amatitlán	215 849	161 455	42.79




Figure 2: Desbalance marcado y heterogéneo entre lagos.

La diferencia de prevalencias hace que accuracy sea insuficiente: un clasificador trivial podría parecer excelente en Atitlán. Por ello se reportan precision, recall, F1 y ROC-AUC. Desde vigilancia ambiental se prioriza recall, porque un falso negativo omite una zona potencialmente problemática; un falso positivo incrementa muestreo y costos, pero permite confirmación de campo.

4 Predictores e ingeniería de variables

La ecuación Se2WaQ usada en la Parte 1 es $115530.31[(B03\ B04)/B02]^{2.38}$. La Tabla 3 documenta la exclusión estricta de variables con fuga.

Table 3: Variables excluidas del entrenamiento.

Variable	Motivo
CYA	Variable continua que define directamente la etiqueta.
B02, B03, B04	Entran directamente en la ecuación de CYA.
NDVI	Usa B04, que participa en la construcción de CYA.
NDWI	Usa B03, que participa en la construcción de CYA.

Los predictores espectrales seguros son B05, B06 y B07 (borde rojo), B08 y B8A (infrarrojo cercano) y B11/B12 (infrarrojo de onda corta). Se añadieron coordenadas normalizadas dentro de cada lago para representar estructura espacial sin usar la separación absoluta entre lagos, y seno/coseno del día del año para codificar estacionalidad circular. El lago no se utilizó como predictor, lo que hace más honesta la transferencia cruzada.

5 Modelos y ajuste

Se aplicó una partición estratificada convencional de 70% entrenamiento y 30% prueba. Dentro del entrenamiento, una búsqueda en rejilla con tres pliegues seleccionó hiperparámetros por ROC-AUC sobre un máximo de 50 000 filas. Después se reajustó cada modelo con todo el entrenamiento y se conservó el mismo test para comparar.

Table 4: Mejor configuración por algoritmo.

Modelo	Configuración seleccionada	ROC-AUC CV
Regresión logística	$C = 10$, estandarización, pesos balanceados	0.994
Random Forest	120 árboles, profundidad libre, hoja mínima 2	0.998
Gradient Boosting	tasa 0.10, 31 hojas, 160 iteraciones	0.998

6 Evaluación aleatoria, espacial y temporal

Table 5: Métricas principales. GroupKFold espacial es el promedio de cinco pliegues.

Validación	Modelo	Accuracy	Precision	Recall	F1 / AUC
Aleatoria	Logística	0.967	0.874	0.989	0.928 / 0.995
Aleatoria	Random Forest	0.984	0.952	0.973	0.963 / 0.999
Aleatoria	Gradient Boosting	0.981	0.930	0.987	0.957 / 0.999
Espacial	Logística	0.967	0.874	0.986	0.927 / 0.995
Espacial	Random Forest	0.982	0.952	0.963	0.958 / 0.998
Espacial	Gradient Boosting	0.979	0.927	0.981	0.953 / 0.998
Temporal	Logística	0.870	0.687	0.938	0.794 / 0.959
Temporal	Random Forest	0.776	0.992	0.162	0.279 / 0.903
Temporal	Gradient Boosting	0.850	0.816	0.561	0.665 / 0.908

Gradient Boosting se seleccionó por el mayor ROC-AUC aleatorio y recall alto. Random Forest obtuvo el F1 aleatorio más alto por margen pequeño, pero su recall temporal cayó a 0.162: fue demasiado conservador ante las últimas fechas (Atitlán 2026-07-22 y Amatitlán 2026-06-19). La regresión logística resultó menos precisa pero mucho más estable en recall temporal. Esta tensión impide declarar un único algoritmo “mejor” sin especificar el objetivo ambiental.



Figure 3: La partición aleatoria sobreestima el comportamiento frente a cambio temporal y de lago.

6.1 Validación espacial por bloques

Las coordenadas se proyectaron a EPSG:32615 y se asignó cada píxel a una cuadrícula de 1 km. Se obtuvieron 167 bloques en Atitlán y 36 en Amatitlán. GroupKFold mantuvo todas las fechas de un mismo bloque exclusivamente en entrenamiento o prueba, evitando que el mismo lugar reapareciera en ambos conjuntos.




Figure 4: Centroides de los bloques espaciales y cantidad de observaciones muestreadas.

Las métricas espaciales fueron cercanas a las aleatorias, lo que sugiere que las bandas independientes contienen señal transferible entre bloques. Sin embargo, GroupKFold reparte bloques no contiguos entre pliegues y conserva vecindad entre bloques adyacentes; en el corte final conviene contrastar además particiones espaciales contiguas si el presupuesto computacional lo permite.

7 Transferencia entre lagos

Table 6: Prueba cruzada: entrenamiento en un lago y evaluación en el otro.

Dirección	Modelo	Precision	Recall	F1	ROC-AUC
Atitlán → Amatitlán	Logística	0.691	0.960	0.804	0.930
	Random Forest	0.964	0.364	0.529	0.938
	Gradient Boosting	0.865	0.658	0.747	0.869
Amatitlán → Atitlán	Logística	0.580	0.951	0.721	0.998
	Random Forest	0.580	0.932	0.715	0.994
	Gradient Boosting	0.441	0.943	0.601	0.999

La generalización es asimétrica. Atitlán tiene apenas 0.36% de positivos reales, por lo que entrenar allí limita la diversidad de episodios altos y reduce el recall en Amatitlán para los árboles. En sentido inverso, los modelos reconocen la mayoría de positivos escasos de Atitlán, pero con precisión moderada: numerosos espectros son marcados como altos en un lago donde la prevalencia es mínima. Las diferencias de profundidad, mezcla, altitud, cuenca y presión urbana hacen que un umbral espectral aprendido en un lago no sea automáticamente transportable.

8 Importancia global preliminar

La importancia por permutación del Gradient Boosting se calculó sobre una muestra independiente del test. B05 produjo la mayor caída de ROC-AUC (0.266), muy por encima de B08 (0.008) y la posición norte normalizada (0.005). B05 se ubica en el borde rojo, una región sensible a pigmentos y cambios ópticos de biomasa. Esta asociación es predictiva, no causal; materia suspendida, profundidad y condiciones atmosféricas pueden producir respuestas parecidas.




Figure 5: Importancia global por permutación del modelo seleccionado.

9 Conclusiones preliminares y trabajo restante

El avance demuestra que es posible clasificar el proxy CYA con bandas no usadas en su construcción y obtener alta discriminación bajo validación aleatoria y espacial. La caída temporal y la transferencia asimétrica son resultados centrales: un modelo operativo requiere seguimiento de cambio de distribución y calibración local. Para vigilancia, la regresión logística ofrece el recall temporal más seguro; Gradient Boosting ofrece el mejor balance global en el corte actual.

El 25% final comprenderá:

1. SHAP global y local, con dirección y magnitud de efectos;
2. mapas por lago de probabilidad y categorías de riesgo;
3. mapas de falsos positivos y falsos negativos, comparados con la Parte 1;
4. conclusiones definitivas, limitaciones, propuesta de muestreo in situ y datos adicionales.

Referencias

1. World Health Organization. *Guidelines on recreational water quality: Volume 1, coastal and fresh waters*. 2021. <https://www.who.int/publications/i/item/9789240031302>
2. U.S. Environmental Protection Agency. *WHO 1999 Guideline Values for Cyanobacteria in Freshwater*.
3. Sentinel Hub. *Se2WaQ – Sentinel-2 Water Quality*. <https://custom-scripts.sentinel-hub.com/custom-scripts/sentinel-2/se2waq/>
4. Copernicus Data Space Ecosystem. *openEO API*. <https://openeo.dataspace.copernicus.eu/>