

Universidad del Valle de Guatemala

Data Science ù Sección 10

Laboratorio 4

ML y GIS ù Parte 2

Informe final

Clasificación, validación geoespacial e interpretación de concentraciones de cianobacterias en los lagos de Atitlán y Amatitlán

Jorge Gabriel Palacios Sales	231385
Pablo Daniel Barillas Moreno	22193
Roberto Emiliano Otoniel	23968

20 de agosto de 2026

Abstract

Se construyó un conjunto supervisado a nivel píxel–fecha con 22 observaciones Sentinel-2 L2A de los lagos de Atitlán y Amatitlán. Después de recortar los GeoJSON oficiales, filtrar calidad, identificar agua y calcular los índices de la Parte 1, quedaron 3,419,056 píxeles válidos; para modelado se tomó una muestra reproducible y balanceada por lago–fecha de 220,000 filas. La respuesta binaria identifica valores del proxy Se2WaQ iguales o superiores a 100,000 células/mL. Para evitar fuga se excluyeron CYA, B02, B03, B04, NDVI y NDWI. Se compararon regresión logística, Random Forest y Gradient Boosting con prueba aleatoria 70/30, GroupKFold espacial, retención temporal y transferencia entre lagos. Gradient Boosting obtuvo ROC-AUC 0.9987 y F1 0.9572 en la prueba aleatoria, pero F1 0.6651 en la fecha futura; la regresión logística conservó el mayor recall temporal (0.9384). SHAP atribuyó el mayor efecto a B05 y B08. Los mapas finales muestran riesgo casi nulo en la última escena de Atitlán y alta probabilidad en gran parte de Amatitlán. Los resultados respaldan el uso del modelo como herramienta de priorización, no como sustituto de mediciones limnológicas o sanitarias in situ.

Contents

1	Objetivo y diseño del análisis	1
2	Preparación y exploración del dataset	1
2.1	Fuente, estructura y limpieza	1
3	Definición de la respuesta y desbalance	1
4	Predictores e ingeniería de variables	3
5	Modelos, ajuste y prueba convencional	4
6	Validación espacial y temporal	4
6.1	Cuadrícula y GroupKFold espacial	4
6.2	Comparación de escenarios	5
7	Generalización entre lagos	6
8	Interpretación del modelo	7
8.1	Importancia global	7
8.2	SHAP global, dirección y casos locales	8
9	Mapas predictivos y errores espaciales	11
9.1	Desempeño esperado sobre la población completa	13
10	Conclusiones, utilidad y limitaciones	13
11	Reproducibilidad y entregables	14

1 Objetivo y diseño del análisis

El objetivo fue predecir si un píxel acuático presenta una concentración alta o baja del índice de cianobacterias de la Parte 1, evaluar cuánto se generaliza el modelo en el espacio, el tiempo y entre lagos, interpretar sus predicciones y representar cartográficamente el riesgo. La unidad de análisis es un píxel válido de 20 m observado en una fecha y lago específicos. Todo el flujo es reproducible mediante los scripts, el notebook ejecutado, las tablas y las figuras incluidos en el repositorio.

2 Preparación y exploración del dataset

2.1 Fuente, estructura y limpieza

Se procesaron las once fechas oficiales por lago. Cada fila conserva lago, fecha, coordenadas UTM 15N y WGS84, bandas espectrales, NDVI, NDWI, CYA, variables temporales, bloque espacial y clase. La máscara SCL excluyó NoData, píxeles defectuosos, sombras, nubes, cirros y nieve. También se exigió reflectancia positiva, pertenencia al GeoJSON y NDWI mayor o igual que cero. Los porcentajes de la Tabla 1 usan como denominador la envolvente rectangular del raster y, por ello, representan conjuntamente recorte geométrico, agua y calidad; no son porcentajes de nubosidad.

Table 1: Inventario completo previo al muestreo de modelado.

Lago	Fechas	Píxeles raster	Válidos	Válidos (%)
Atitlán	11	7,725,564	3,041,752	39.37
Amatitlán	11	1,926,210	377,304	19.59
Total	22	9,651,774	3,419,056	35.42

El dataset completo no presenta valores faltantes en las variables analíticas. Para reducir el costo de ajuste se seleccionaron como máximo 10,000 píxeles por lago-fecha, sin sobremuestreo de la clase positiva: 220,000 observaciones y 27 columnas. Esta muestra mantiene representación idéntica por escena; los conteos de limpieza y prevalencia se calcularon sobre todos los píxeles válidos, no solo sobre la muestra.




Figure 1: Distribuciones y relaciones exploratorias de CYA, NDVI y NDWI.

3 Definición de la respuesta y desbalance

Se definió $Y = 1$ cuando $CYA (10^3 \text{ células/mL}) \geq 100$, equivalente a 100,000 células/mL. El valor se adoptó como umbral de cribado basado en referencias históricas de la OMS para aguas recreativas.

No constituye por sí mismo una declaración toxicológica: Se2WaQ es un proxy óptico transferido y no mide taxonomía, toxinas ni recuentos microscópicos. Una alerta debe confirmarse mediante muestreo de campo.

Table 2: Distribución completa de la respuesta por lago.

Lago	Baja	Alta	Alta (%)
Atitlán	3,030,910	10,842	0.36
Amatitlán	215,849	161,455	42.79
Global	3,246,759	172,297	5.04




Figure 2: Desbalance global y diferencias marcadas entre lagos.

La prevalencia cambia además entre fechas, como muestra la Figura 3. Un modelo trivial que prediga siempre “baja” alcanzaría accuracy elevada en Atitlán; por ello se reportan precision, recall, F1 y ROC-AUC junto con la matriz de confusión. Desde vigilancia ambiental se prioriza recall: un falso negativo puede omitir una zona que requiere inspección, mientras que un falso positivo aumenta el costo de muestreo, pero todavía permite confirmación.




Figure 3: Porcentaje y conteo de píxeles de clase alta por lago y fecha.

4 Predictores e ingeniería de variables

La ecuación Se2WaQ usada para la etiqueta es

$$CYA = 115530.31 \left(\frac{B03 B04}{B02} \right)^{2.38}.$$

Se aplicó una exclusión conservadora de fuga de información.

Table 3: Variables excluidas del entrenamiento.

Variable	Motivo
CYA	Variable continua que define directamente la etiqueta.
B02, B03, B04	Participan directamente en la ecuación del proxy CYA.
NDVI	Utiliza B04, que también participa en la construcción de CYA.
NDWI	Utiliza B03, que también participa en la construcción de CYA.

Los predictores finales son B05, B06 y B07 (borde rojo), B08 y B8A (infrarrojo cercano), B11 y B12 (infrarrojo de onda corta), coordenadas x/y normalizadas dentro de cada lago y seno/coseno del día del año. Las variables cíclicas evitan la discontinuidad artificial entre diciembre y enero. El nombre del lago no se empleó como predictor, para no entregar al modelo una separación geográfica directa y hacer más honesta la transferencia entre lagos.

5 Modelos, ajuste y prueba convencional

Se compararon regresión logística, Random Forest y Gradient Boosting. La partición convencional fue estratificada: 70% entrenamiento y 30% prueba. Dentro del entrenamiento, una búsqueda en rejilla con tres pliegues optimizó ROC-AUC sobre hasta 50,000 filas. Después, cada configuración se reajustó con todo el entrenamiento y se evaluó en el mismo conjunto de prueba de 66,000 observaciones.

Table 4: Hiperparámetros seleccionados.

Modelo	Configuración	ROC-AUC CV
Regresión logística	$C = 10$, escalamiento y pesos balanceados	0.9945
Random Forest	120 árboles, profundidad libre, hoja mínima 2	0.9983
Gradient Boosting	tasa 0.10, 31 hojas, 160 iteraciones	0.9983

Table 5: Resultados de la prueba aleatoria común.

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC
Regresión logística	0.9670	0.8738	0.9894	0.9280	0.9948
Random Forest	0.9838	0.9520	0.9735	0.9626	0.9987
Gradient Boosting	0.9810	0.9296	0.9865	0.9572	0.9987

Random Forest alcanzó el F1 aleatorio más alto y Gradient Boosting el ROC-AUC más alto, pero ninguna de las dos diferencias es concluyente: los ROC-AUC distan 4×10^{-5} en una única partición, sin intervalo de confianza. El código trata como empatados a los modelos que caen dentro de una tolerancia de 10^{-3} y desempata por recall, criterio prioritario en vigilancia ambiental; con esa regla se selecciona Gradient Boosting como modelo explicativo y cartográfico. La regresión logística sacrificó precisión, pero omitió menos positivos.




Figure 4: Matrices de confusión en la prueba aleatoria 70/30.

6 Validación espacial y temporal

6.1 Cuadrícula y GroupKFold espacial

Las coordenadas se expresaron en EPSG:32615 y se asignó cada observación a una cuadrícula de aproximadamente 1 km. Se identificaron 167 bloques con datos en Atitlán y 36 en Amatitlán. GroupKFold

de cinco pliegues mantuvo cada bloque completo en entrenamiento o prueba. Así se evita que píxeles del mismo kilómetro aparezcan en ambos conjuntos, aunque bloques vecinos todavía pueden quedar en pliegues distintos.




Figure 5: Polígonos de la cuadrícula espacial de 1 km y observaciones muestreadas.

6.2 Comparación de escenarios

La validación temporal retuvo la última fecha completa de cada lago (Atitlán: 22 de julio de 2026; Amatitlán: 19 de junio de 2026) y entrenó exclusivamente con fechas anteriores. Esta prueba mide cambio de distribución y se acerca más al uso prospectivo.

Table 6: Métricas espaciales y temporales. La fila espacial es el promedio de cinco pliegues.

Validación	Modelo	Accuracy	Precision	Recall	F1	AUC
Espacial	Logística	0.9667	0.8741	0.9863	0.9267	0.9947
Espacial	Random Forest	0.9818	0.9523	0.9631	0.9576	0.9981
Espacial	Gradient Boosting	0.9794	0.9274	0.9809	0.9533	0.9982
Temporal	Logística	0.8700	0.6874	0.9384	0.7936	0.9590
Temporal	Random Forest	0.7765	0.9920	0.1620	0.2785	0.9034
Temporal	Gradient Boosting	0.8495	0.8164	0.5611	0.6651	0.9080




Figure 6: Comparación entre evaluación aleatoria, espacial, temporal y entre lagos.

El desempeño espacial cercano al aleatorio indica señal espectral transferible entre los bloques observados. En contraste, la caída temporal es sustancial: Random Forest se vuelve muy conservador y su recall baja a 0.1620; Gradient Boosting pierde 0.2921 puntos de F1 frente a la prueba aleatoria. La regresión logística generaliza mejor en recall temporal. Por tanto, no existe un único “mejor” algoritmo sin especificar el costo del error: Gradient Boosting equilibra discriminación y explicación, mientras que la regresión logística es más segura para priorizar no omitir alertas futuras.

Esta prueba se apoya en dos escenas, y conviene no atribuir la caída al paso del tiempo sin matizarla. La retención de Atitlán (0.16% de positivos) es indistinguible de sus otras diez fechas, así que casi toda la degradación proviene de la escena de Amatitlán, que reúne dos particularidades: es la más nubosa de todo el conjunto (13% frente a 5% o menos en las 21 restantes) y es la única con floración intermedia, 53.6% de píxeles altos, cuando toda fecha de entrenamiento del lago está por debajo de 0.4% o por encima de 70%. La retención mide entonces un régimen de floración no observado antes, combinado con menor calidad de escena, más que el efecto del tiempo transcurrido. La conclusión operativa se mantiene — la partición aleatoria es optimista y hay cambio de distribución —, pero su magnitud exacta requiere más fechas retenidas, idealmente una validación dejando fuera cada fecha por turno.

7 Generalización entre lagos

Cada modelo se entrenó con las 110,000 observaciones muestreadas de un lago y se evaluó sobre las 110,000 del otro, sin reajuste.

Table 7: Transferencia entre lagos.

Dirección	Modelo	Precision	Recall	F1	ROC-AUC
Atitlán → Amatitlán	Logística	0.691	0.960	0.804	0.930
	Random Forest	0.964	0.364	0.529	0.938
	Gradient Boosting	0.865	0.658	0.747	0.869
Amatitlán → Atitlán	Logística	0.580	0.951	0.721	0.998
	Random Forest	0.580	0.932	0.715	0.994
	Gradient Boosting	0.441	0.943	0.601	0.999

Conviene contrastar cada dirección con su clasificador trivial. En Amatitlán → Atitlán la prevalencia de destino es 0.33%, de modo que predecir siempre “baja” alcanza accuracy 0.9967: los tres modelos quedan en ese nivel o por debajo (Gradient Boosting, 0.9958). El accuracy no aporta información en esa dirección y solo precision, recall y ROC-AUC resultan informativos; por la misma razón, promediar las dos direcciones en una sola fila — como hace la tabla de resumen reproducible — mezcla escenarios con prevalencias de 42.7% y 0.33% y no debe leerse como un desempeño típico.

La generalización es asimétrica y peor que la evaluación dentro de la mezcla de ambos lagos. Atitlán aporta solo 0.36% de positivos, por lo cual entrenar allí ofrece pocos episodios altos y reduce el recall de los modelos de árboles cuando se aplican a Amatitlán. En sentido inverso, los modelos detectan la mayoría de los positivos escasos de Atitlán, pero con precisión moderada. Profundidad, mezcla, altitud, materia suspendida, uso del suelo y presión urbana modifican la firma óptica; un clasificador aprendido en un lago no debe transferirse sin calibración local.

8 Interpretación del modelo

8.1 Importancia global

La importancia por permutación del Gradient Boosting se midió sobre prueba independiente. B05 produjo la mayor caída del ROC-AUC (0.266), seguida a distancia por B08 y la coordenada norte normalizada. B05 se ubica en el borde rojo, región sensible a cambios de pigmentos y biomasa, pero su asociación es predictiva, no causal: turbidez, profundidad y corrección atmosférica pueden inducir respuestas similares.




Figure 7: Importancia global por permutación.

8.2 SHAP global, dirección y casos locales

TreeExplainer se aplicó a 4,000 observaciones de prueba del Gradient Boosting, muestreadas de forma deliberadamente balanceada (2,000 de cada clase). Esa mezcla 50/50 no es la del conjunto de prueba (21.5% alta) ni la poblacional (5.04%), por lo que el valor base y las magnitudes deben leerse como efectos relativos y no como probabilidades esperadas en campo. El valor absoluto SHAP promedio confirmó el dominio de B05 (6.916), seguido a gran distancia por B08 (0.995), posición norte (0.340), posición este (0.257) y estacionalidad coseno (0.254). Valores altos de B05 y B08 aumentan la predicción, y la componente espacial indica heterogeneidad persistente, no causalidad geográfica.

Las direcciones de las bandas restantes no se interpretan. B07 (783 nm), B08 (842 nm) y B8A (865 nm) son contiguas y casi colineales dentro del píxel, y sin embargo reciben signos alternos: positivo la del medio, negativos sus dos vecinas. Con magnitudes de 0.086 y 0.069 frente a los 6.916 de B05 — alrededor del 1% — esos signos son un artefacto del reparto de cortes entre variables redundantes, no una respuesta óptica. El resumen tabulado marca como **no_concluyente** toda variable cuya señal quede por debajo del 5% de la dominante.




Figure 8: Resumen SHAP: magnitud y dirección de los efectos sobre el logit.




Figure 9: Magnitud SHAP media absoluta de los predictores.

Las explicaciones locales de una predicción alta y una baja muestran cómo el modelo combina señales: una contribución positiva grande de B05 puede dominar un caso de riesgo, mientras que valores espectrales incompatibles y componentes espaciales negativas sostienen una predicción baja. Estas explicaciones no convierten el modelo en mecanismo biofísico; sirven para auditar consistencia y detectar predicciones sustentadas en variables espurias.




Figure 10: Explicaciones SHAP locales de una predicción alta y una baja.

9 Mapas predictivos y errores espaciales

La última escena de cada lago coincide con la fecha retenida en la validación temporal. Reajustar el modelo sobre las 220,000 filas dejaría dentro del entrenamiento el 29.0% de los píxeles válidos de Amatitlán 2026-06-19 y el 3.3% de los de Atitlán 2026-07-22, de modo que el mapa dejaría de ser comparable con las métricas fuera de muestra. Por eso cada escena se predice con un Gradient Boosting reentrenado sin su propia fecha, conservando los hiperparámetros seleccionados; el modelo ajustado con todas las filas se conserva únicamente como objeto de despliegue. Cada píxel válido se clasificó en baja ($p < 0.33$), media ($0.33 \leq p < 0.67$) y alta ($p \geq 0.67$), con los mismos cortes que emplea la barra de color de las figuras. Las categorías representan confianza del modelo, no nuevos umbrales sanitarios.

Table 8: Resumen de mapas predictivos de la última fecha, cada una predicha sin su propia fecha en el entrenamiento.

Lago	Píxeles	$\bar{p}$	Baja (%)	Media (%)	Alta (%)
Atitlán, 2026-07-22	301,570	0.003	99.77	0.07	0.16
Amatitlán, 2026-06-19	34,483	0.623	31.73	8.70	59.58




Figure 11: Atitlán: CYA observado, probabilidad y categoría predictiva.




Figure 12: Amatitlán: CYA observado, probabilidad y categoría predictiva.

Los mapas son coherentes con la Parte 1: la escena final de Atitlán presenta concentración baja casi generalizada, mientras que Amatitlán mantiene un patrón amplio de riesgo alto. La comparación no es una validación independiente, porque la clase observada proviene del mismo proxy remoto y se calcula sobre el mismo píxel que alimenta al modelo; su utilidad es verificar concordancia espacial y priorizar puntos de muestreo. El mapa de Amatitlán debe leerse junto con la fila temporal del cuadro de escenarios: sobre esa misma escena el Gradient Boosting alcanza recall 0.5611 y F1 0.6651, muy por debajo de su desempeño aleatorio, de modo que la concordancia visual global convive con una omisión apreciable de píxeles altos.

Los errores cartografiados proceden de predicciones fuera de muestra de los cinco pliegues espaciales de Gradient Boosting. En la muestra de 220,000 filas hubo 3,640 falsos positivos y 889 falsos negativos; Amatitlán concentró 862 FN y 3,572 FP, mientras Atitlán tuvo 27 FN y 68 FP. Los errores se agrupan en transiciones y zonas heterogéneas, donde mezcla de píxel, borde de agua, turbidez o cambio temporal pueden alterar la señal.




Figure 13: Verdaderos y falsos resultados fuera de muestra bajo GroupKFold espacial.

9.1 Desempeño esperado sobre la población completa

Las métricas anteriores se calculan sobre la muestra de modelado, que asigna a Amatitlán la mitad de las filas aunque aporte el 11% de los píxeles válidos, y eleva la prevalencia a 21.5% frente al 5.04% real. Dentro de cada escena el muestreo sí es uniforme, de modo que las tasas por escena son insesgadas: reponderar TPR y FPR de cada lago–fecha por su conteo real de clases devuelve el desempeño esperado sobre los 3,419,056 píxeles válidos.

Table 9: Gradient Boosting fuera de muestra, reponderado a la población completa.

Alcance	Píxeles	Prev. real	Precision	Recall	F1	FP	FN
Global	3,419,056	5.04%	0.9203	0.9783	0.9484	14,606	3,741
Amatitlán	377,304	42.79%	0.9267	0.9816	0.9533	12,542	2,976
Atitlán	3,041,752	0.36%	0.8300	0.9294	0.8769	2,064	765

El resultado agregado apenas se mueve: la precision global pasa de 0.9274 en la muestra a 0.9203 en la población, porque el modelo mantiene una tasa de falsos positivos muy baja donde la clase negativa domina. Lo que el promedio ocultaba es la diferencia entre lagos. En Amatitlán la precision poblacional es 0.9267, pero en Atitlán cae a 0.8300: sobre un lago donde solo el 0.36% de los píxeles es realmente alto, se esperan unos 2,064 falsos positivos frente a 10,077 verdaderos, es decir aproximadamente una de cada seis alertas sería falsa. Para vigilancia esto no invalida el modelo — el recall se mantiene en 0.9294 y el costo de un falso positivo es una inspección adicional —, pero sí implica que el umbral operativo debe calibrarse por lago y no globalmente.

10 Conclusiones, utilidad y limitaciones

1. Es posible reconstruir el proxy CYA con bandas que no intervienen en su fórmula, pero conviene ser preciso sobre qué mide ese resultado. La etiqueta es una función algebraica determinista de B02, B03 y B04 del mismo píxel, y las bandas admitidas no son independientes de ellas: B05

(705 nm) es contigua a B04 (665 nm) y casi colineal dentro del píxel. Excluir las variables elimina la circularidad formal, no la información, y por eso B05 concentra por sí sola 0.266 de la caída de ROC-AUC y el discriminante alcanza 0.9987. El ejercicio demuestra interpolación espectral robusta; no constituye evidencia de detección de cianobacterias validada contra verdad de campo, que no existe en este conjunto.

2. La prueba aleatoria es optimista para uso operativo. La validación temporal reveló degradación fuerte, en especial del recall de Random Forest. Cualquier despliegue requiere monitorear cambio de distribución y reentrenar con campañas nuevas.
3. La validación espacial fue estable dentro de la cobertura estudiada, pero la transferencia entre lagos fue asimétrica. Se recomienda calibración por lago y conservar evaluación separada por cuerpo de agua.
4. B05 y B08 dominan la explicación del Gradient Boosting. Esto es compatible con sensibilidad del borde rojo y NIR a propiedades ópticas del agua, pero SHAP no establece causalidad ni distingue por sí solo cianobacterias de sedimentos u otros pigmentos.
5. Como herramienta ambiental, el sistema sirve para ordenar recorridos, localizar zonas persistentes y priorizar muestras. Si el objetivo es minimizar eventos omitidos, la regresión logística ofrece el recall temporal más favorable; si se busca discriminación global y cartografía, Gradient Boosting ofrece un mejor balance.

Las principales limitaciones son: respuesta derivada de un proxy y no de verdad de campo; solo once fechas por lago; autocorrelación residual entre bloques vecinos; nubes y geometría de adquisición; resolución de 20 m; mezcla en orillas; fuerte diferencia de prevalencia; y evaluación limitada a dos lagos guatemaltecos. Los umbrales de probabilidad no están calibrados como niveles sanitarios.

Quedan además tres limitaciones metodológicas del propio diseño experimental. Primera, los hiperparámetros se buscaron una sola vez sobre una submuestra de la partición aleatoria de entrenamiento y se reutilizaron en los cuatro esquemas; como esa submuestra abarca todos los bloques, ambos lagos y las dos fechas retenidas, las validaciones espacial, temporal y entre lagos arrastran fuga de selección de hiperparámetros y son ligeramente optimistas. El sesgo es pequeño, porque la rejilla tiene dos o tres puntos por modelo, pero un ajuste anidado dentro de cada esquema lo eliminaría. Segunda, ambas rejillas seleccionaron valores en el borde del espacio explorado — profundidad libre y hoja mínima 2 en Random Forest, tasa 0.10 y 31 hojas en Gradient Boosting —, señal de que el óptimo probablemente queda fuera y de que conviene ampliarlas. Tercera, las coordenadas normalizadas figuran entre los predictores, lo que permite al modelo interpolar hacia bloques vecinos retenidos y debilita en parte el aislamiento que busca GroupKFold; su efecto es menor, 0.005 de caída de ROC-AUC por permutación, pero una evaluación estricta debería repetirse sin ellas.

Para fortalecer el modelo se necesitan conteos celulares y taxonómicos georreferenciados, clorofila-a, ficocianina y toxinas; temperatura, pH, oxígeno disuelto, turbidez, transparencia y nutrientes; profundidad y batimetría; viento y precipitación acumulada; descargas, uso del suelo y tratamiento de aguas; más fechas y años, incluyendo estación lluviosa y seca; y sensores complementarios o productos atmosféricos. Una siguiente evaluación debería usar campañas prospectivas, bloques espaciales contiguos y calibración explícita de probabilidades.

11 Reproducibilidad y entregables

El repositorio contiene el notebook final ejecutado, el informe en L^AT_EX y PDF, el código modular, las pruebas automatizadas, las tablas y figuras. Los 22 GeoTIFF y productos derivados de gran tamaño se

mantienen fuera de Git mediante `.gitignore`; pueden regenerarse con los scripts documentados. Las credenciales de Copernicus nunca se escriben en archivos: la descarga usa autenticación por código de dispositivo.

Referencias

1. World Health Organization. *Guidelines on recreational water quality: Volume 1, coastal and fresh waters*. 2021. <https://www.who.int/publications/i/item/9789240031302>
2. U.S. Environmental Protection Agency. *WHO 1999 Guideline Values for Cyanobacteria in Freshwater*.
3. Sentinel Hub. *Se2WaQ – Sentinel-2 Water Quality*. <https://custom-scripts.sentinel-hub.com/custom-scripts/sentinel-2/se2waq/>
4. Copernicus Data Space Ecosystem. *openEO API*. <https://openeo.dataspace.copernicus.eu/>
5. Lundberg, S. M. y Lee, S.-I. *A Unified Approach to Interpreting Model Predictions*. NeurIPS, 2017.