

LABORATORIO 4

ML y GIS

Parte 2 · Clasificación geoespacial de cianobacterias

PRESENTACIÓN DEL REPOSITORIO · AVANCE 75%



Escanee para abrir el repositorio

ABRIR REPOSITORIO EN GITHUB

Grupo 1

Jorge Gabriel Palacios Sales · Pablo Daniel Barillas Moreno
Roberto Emiliano Otoniel

Guatemala · Agosto de 2026

01

Ficha académica

INSTITUCIÓN	Universidad del Valle de Guatemala
CURSO	Data Science
SECCIÓN	10
LABORATORIO	Laboratorio 4: ML y GIS — Parte 2
GRUPO	Grupo 1
ESTADO	Avance reproducible del 75%

02

Propósito del proyecto

El laboratorio integra sensores remotos, análisis geoespacial y aprendizaje automático para clasificar concentraciones altas y bajas del proxy de cianobacterias Se2WaQ en los lagos de Atitlán y Amatitlán. La unidad de análisis es un píxel acuático válido de Sentinel-2 asociado con ubicación, fecha, lago, información espectral y variables derivadas.

El repositorio documenta todo el flujo reproducible: descarga desde Copernicus Data Space Ecosystem, control de calidad, construcción del dataset, entrenamiento de modelos y validaciones aleatoria, espacial, temporal y cruzada entre lagos.

22	3.42 M	220 K	3
fechas oficiales	píxeles válidos	filas de ML	modelos comparados

03

Integrantes

Nombre completo	Carné
Jorge Gabriel Palacios Sales	231385
Pablo Daniel Barillas Moreno	22193
Roberto Emiliano Otoniel	23968

1

Sentinel-2

2

Limpieza

3

Features

4

Modelos

5

Validación

- Datos: 22 fechas oficiales Sentinel-2 L2A, 11 por lago, a 20 m de resolución.
- Variables descargadas: diez bandas espectrales, NDVI, NDWI y CYA.
- Modelos: regresión logística, Random Forest y Gradient Boosting.
- Validación: división 70/30, GroupKFold espacial, retención temporal y transferencia entre lagos.
- Métricas: accuracy, precision, recall, F1, ROC-AUC y matrices de confusión.

CONTROL DE FUGA DE INFORMACIÓN

CYA, B02, B03, B04, NDVI y NDWI se conservan para trazabilidad, pero se excluyen del entrenamiento porque participan directa o indirectamente en la construcción de la respuesta.

Escenario	Modelo destacado	Métrica	Resultado
Aleatorio 70/30	Gradient Boosting	ROC-AUC	0.9987
Aleatorio 70/30	Random Forest	F1	0.9626
Temporal	Regresión logística	Recall	0.9384
Datos completos	Amatitlán / Atitlán	CYA alta	42.79% / 0.36%

La diferencia entre los resultados aleatorios y temporales evidencia que la capacidad predictiva debe evaluarse bajo cambios de fecha y territorio. Desde vigilancia ambiental, el recall es especialmente relevante porque un falso negativo puede omitir una zona potencialmente problemática.



ACCESO DIRECTO

Repositorio oficial

https://github.com/DanielBarillasM/Laboratorio-4.-ML-y-GIS_Grupo-1_DS_Sec-10

URL para clonar

`https://github.com/DanielBarillasM/Laboratorio-4.-ML-y-GIS_Grupo-1_DS_Sec-10.git`

Propietario: **DanielBarillasM**

Rama principal: **main**

NOTEBOOK

Análisis ejecutado con narrativa, tablas y figuras.

INFORME

Documento LaTeX y PDF con metodología, resultados e interpretación.

CÓDIGO

Descarga openEO, preparación del dataset, modelos y validaciones.

RESULTADOS

Métricas, matrices de confusión, figuras espaciales e importancia global.

```
uv sync --extra test
uv run python scripts/download_ml_stack.py --lake all --submit
uv run python scripts/build_ml_dataset.py
uv run python scripts/run_ml_advance.py
uv run pytest -q
```

Nota de entrega: antes de compartir este documento, debe comprobarse que la versión local más reciente haya sido confirmada y sincronizada con GitHub. Los GeoTIFF y datasets grandes permanecen fuera de Git por diseño y se reconstruyen mediante los scripts.