

LABORATORIO 4

ML y GIS

Parte 2 · Clasificación geoespacial de cianobacterias

PRESENTACIÓN DEL REPOSITORIO · ENTREGA FINAL 100%

[ABRIR REPOSITORIO EN GITHUB](#)

Integrante	Carné
Jorge Gabriel Palacios Sales	231385
Pablo Daniel Barillas Moreno	22193
Roberto Emiliano Otoniel	23968

Universidad del Valle de Guatemala · Data Science · Sección 10 · Grupo 1 · Agosto de 2026

01 · Propósito y alcance

El proyecto integra sensores remotos, análisis geoespacial y aprendizaje automático para clasificar concentraciones altas y bajas del proxy Se2WaQ en los lagos de Atitlán y Amatitlán. La unidad analítica es un píxel acuático válido de Sentinel-2 de 20 m asociado con ubicación, fecha, lago y variables espectrales.

22 escenas	3.42 M píxeles válidos	220 K filas de ML	203 bloques de 1 km
----------------------	----------------------------------	-----------------------------	-------------------------------

02 · Metodología

Etapas	Implementación
Datos	22 escenas Sentinel-2 L2A; máscara de calidad, agua y GeoJSON oficiales.
Respuesta	CYA ≥ 100 (100,000 células/mL), como umbral de cribado.
Modelos	Regresión logística, Random Forest y Gradient Boosting con ajuste.
Validación	Aleatoria 70/30, GroupKFold 1 km, temporal y entre lagos.
Interpretación	Permutación, SHAP global/local, mapas de riesgo y FP/FN.

Control de fuga: CYA, B02, B03, B04, NDVI y NDWI se excluyen del entrenamiento porque construyen directa o indirectamente la respuesta.

03 · Resultados destacados

Escenario	Modelo	Métrica	Resultado
Aleatorio 70/30	Gradient Boosting	ROC-AUC	0.9987
Aleatorio 70/30	Random Forest	F1	0.9626
Temporal	Regresión logística	Recall	0.9384
Mapa final	Atitlán	Riesgo bajo	99.77%
Mapa final	Amatitlán	Riesgo alto	59.58%

La caída frente a fechas futuras demuestra que la división aleatoria es optimista. La regresión logística conserva el mejor recall temporal, mientras Gradient Boosting equilibra discriminación, explicación y cartografía. SHAP identifica B05 y B08 como las señales de mayor influencia. El modelo se propone para priorización de campo, no como diagnóstico sanitario.

04 · Contenido del repositorio

Componente	Contenido
Notebook	Análisis final ejecutado con HTML/CSS, tablas, figuras e interpretación.
Informe	Fuente LaTeX e informe final PDF de 15 páginas.
Código	Descarga openEO, dataset, modelos, SHAP, cartografía y pruebas.
Resultados	CSV, matrices, figuras espaciales, mapas de riesgo y errores.
Datos	GeoTIFF y derivados grandes locales, reproducibles y excluidos de Git.

05 · Reproducción rápida

```
uv sync --extra test
uv run python scripts/download_ml_stack.py --lake all --submit
uv run python scripts/build_ml_dataset.py
uv run python scripts/run_ml_final.py
uv run pytest -q
```

Repositorio oficial: https://github.com/DanielBarillasM/Laboratorio-4.-ML-y-GIS_Grupo-1_DS_Sec-10